### Rapport: CineNet

#### Théo RAOUL et Mathusan SELVAKUMAR

27 Mai 2024

### 1 Introduction

Pour ce projet de base de données, nous avons opté pour l'utilisation de datasets réels afin de créer une base de données sur les films, acteurs, réalisateurs, événements et studios. Cette approche permet de concevoir une base de données plus authentique et fidèle à la réalité. Cependant, certaines interactions entre utilisateurs, les projections lors des événements et d'autres éléments ont été générés dynamiquement à l'aide de Python.

Afin de garantir la qualité et la reproductibilité des données, nous avons utilisé une même graine de génération pour l'ensemble du processus.

### 2 Modèle Entité-Association

Le diagramme Entité-Association pour CineNet est fourni en un seul fichier PDF séparemment. Par ailleurs, les noms d'associations sont omis pour des raisons de lisibilité.

### 3 Schéma Relationnel

```
UserRoles (type, name, description)
Users (id, last name, first name, username, email, password hashed, birth date, role type)
Users[role type] \subseteq UserRoles[type]
Countries (country code, name)
Cities (city code, country code, name)
Cities[country\_code] \subseteq Countries[country\_code]
UserLocation (user id, city code)
UserLocation[user id] \subseteq Users[id], UserLocation[city code] \subseteq Cities[city code]
Friendship (initiator id, recipient id, date)
Friendship[initiator id] \subseteq Users[id], Friendship[recipient id] \subseteq Users[id]
Following (follower id, followed id, date)
Following[follower\_id] \subseteq Users[id], Following[followed id] \subseteq Users[id]
Categories (id, name, description)
Posts (id, user id, date, content, parent post id, category id)
Posts[user id] \subseteq Users[id], Posts[parent post id] \subseteq Posts[id], Posts[category id] \subseteq Categories[id]
Tags (id, name)
PostTags (tag id, post id)
PostTags[tag id] \subseteq Tags[id], PostTags[post id] \subseteq Posts[id]
Reactions (user id, post id, emoji_unicode)
Reactions[user id] \subseteq Users[id], Reactions[post id] \subseteq Posts[id]
Events (id, name, date, city code, organizer id, capacity, ticket price)
Events[city code] \subseteq Cities[city code], Events[organizer id] \subseteq Users[id]
Participation (user id, event id, type participation)
Participation[user id] \subseteq Users[id], Participation[event id] \subseteq Events[id]
```

```
Genres (id, name, parent genre id)
Genres[parent genre id] \subseteq Genres[id]
Studios (id, name)
Movies (id, title, duration, release date)
MovieGenres (movie id, genre id)
MovieGenres[movie id] \subseteq Movies[id], MovieGenres[genre id] \subseteq Genres[id]
MovieStudios (studio id, movie id)
MovieStudios[studios[studios[id]]] \subseteq Studios[id], MovieStudios[movie id] \subseteq Movies[id]
People (id, last name, first name, birth date)
PeopleRoles (id, name)
MovieCollaborators (people_id, movie_id, role_id)
MovieCollaborators[people id] \subseteq People[id], MovieCollaborators[movie id] \subseteq Movies[id], MovieCollaborators[people id] \subseteq People[id], MovieCollaborators[movie id] \subseteq Movies[id], MovieCollaborators[people id] \subseteq People[id], MovieCollaborators[movie id] \subseteq Movies[id], MovieCollaborators[movie id] \subseteq People[id], MovieCollaborators[movie id] \subseteq Movies[id], 
borators[role id] \subseteq PeopleRoles[id]
Screenings (event id, movie id, screening time)
Screenings[event id] \subseteq Events[id], Screenings[movie id] \subseteq Movies[id]
UserEventRatings (user id, event id, rating)
UserEventRatings[user id] \subseteq Users[id], UserEventRatings[event id] \subseteq Events[id]
UserMovieRatings (user id, movie id, rating)
UserMovieRatings[user id] \subseteq Users[id], UserMovieRatings[movie id] \subseteq Movies[id]
MovieRecommendation (user id, movie id, score recommendation)
MovieRecommendation[user id] \subseteq Users[id], MovieRecommendation[movie id] \subseteq Movies[id]
{\bf CompletedEventRecommendation} \ (user\_id,\ event\_id,\ score\_recommendation)
CompletedEventRecommendation[user id] \subseteq Users[id], CompletedEventRecommendation[event id] \subseteq
Events[id]
ScheduledEventRecommendation (user id, event id, score recommendation)
ScheduledEventRecommendation[user id] \subseteq Users[id], ScheduledEventRecommendation[event id] \subseteq
Events[id]
PostRecommendation (user_id, post_id, score_recommendation)
PostRecommendation[user id] \subseteq Users[id], PostRecommendation[post id] \subseteq Posts[id]
```

#### 4 Les Choix et Limites de la Modélisation

Pour le projet CineNet, nous avons opté pour une base de données centrée exclusivement sur les films, excluant les séries télévisées. Cette décision vise à simplifier la modélisation et la gestion de la base de données. Les films sont des entités relativement simples à modéliser et suffisamment nombreux pour permettre une analyse pertinente. De plus, ils sont des objets culturels très populaires, souvent utilisés comme références dans les discussions sur le cinéma. Nous avons donc choisi de nous concentrer uniquement sur les films pour ce projet.

#### Table UserRoles

Bien que la table UserRoles puisse sembler peu intéressante à première vue, elle a été conçue pour permettre des permissions variées selon les différents types d'utilisateurs. Un utilisateur lambda a un rôle moins important qu'un studio de production, par exemple. L'attribut permission permettrait d'implémenter des fonctionnalités plus avancées selon le type d'utilisateur.

#### Tables Cities, Countries et UserLocations

Les utilisateurs peuvent indiquer leur ville de résidence, et les tables Cities, Countries et UserLocations facilitent la localisation des utilisateurs. Connaître la ville de résidence permet de créer des requêtes intéressantes, telles que la recherche d'événements avant lieu dans une ville spécifique.

### Table Friendships

Un utilisateur peut être ami avec un autre, mais une seule direction est créée dans la table Friendships. Cela peut sembler être une limitation, car il faut vérifier les deux sens pour confirmer une amitié. Toutefois, cette approche permet de différencier celui qui a initié la demande et la date de la demande.

#### Table Following

Un utilisateur peut suivre un autre utilisateur sans que ce dernier ne le suive en retour, permettant ainsi une asymétrie dans les relations de suivi.

#### Table Categories

Les catégories de forums sont limitées au premier niveau, à l'instar des subreddits sur Reddit. Il n'est pas possible d'avoir un sous-forum dans un autre, ce qui simplifie la structure et l'utilisation.

#### Table Posts

Une publication est signée par un utilisateur (l'auteur) qui possède un nom d'utilisateur et un mot de passe crypté pour une connexion sécurisée. Une publication peut ou non être une réponse à une autre publication et peut ou non appartenir à une catégorie. Ne pas avoir de catégorie signifie que la publication est générale.

### Système de Mots-Clés

Grâce aux tables Tags et PostTags, il est possible de faire des recherches rapides en utilisant des titres de films, des noms d'acteurs ou des genres cinématographiques comme mots-clés. Les recherches plus avancées, telles que l'affichage des sous-genres pour un genre donné, doivent être effectuées au niveau de l'application en utilisant les tags et en comparant avec la table des genres, puis en récupérant récursivement les sous-genres.

#### Réactions aux Publications

Les utilisateurs peuvent réagir aux publications avec des emojis représentant différentes appréciations.

#### Table Events

Les utilisateurs peuvent indiquer leur intérêt ou leur participation effective à un événement. Les événements peuvent avoir trois états : Scheduled (Prévu), Completed (Fini), ou Cancelled (Annulé).

### 5 Requêtes

### 5.1 Requête SQL pour la Récupération des Utilisateurs Participant à un Événement Planifié

Cette requête SQL implique au moins trois tables pour récupérer des événements. Elle sélectionne le nom d'utilisateur des utilisateurs participant à un événement planifié dans une ville et un pays spécifiques où ils sont situés. La requête reçoit deux paramètres : le nom de l'événement et le nom de la ville.

```
SELECT
U.username,
E.date
FROM
Users U
JOIN UserLocations UL ON U.id = UL.user_id
JOIN Cities C ON UL.city_code = C.city_code
JOIN Countries CO ON C.country_code = CO.country_code
JOIN Participation P ON U.id = P.user_id
JOIN Events E ON P.event_id = E.id
WHERE
```

```
E.status = 'Scheduled'

AND P.type_participation = 'Participating'

AND E.name = :eventname

AND CO.name = :countryname
;
```

# 5.2 Requête SQL pour la Récupération des Utilisateurs Suivant un Utilisateur Spécifique

Cette requête SQL implique une auto-jointure de la table Users pour récupérer les utilisateurs qui suivent un autre utilisateur. Elle sélectionne le nom d'utilisateur des utilisateurs qui suivent un utilisateur spécifique. La requête reçoit un paramètre : le nom d'utilisateur.

```
SELECT
A.username AS Follower,
B.username AS Followed
FROM
Users A
JOIN FOLLOWING F ON A.id = F.follower_id
JOIN Users B ON F.followed_id = B.id
WHERE
B.username = :username;
```

### 5.3 Requête SQL pour la Récupération des Utilisateurs Suivant un Nombre Minimum d'Utilisateurs

Cette requête SQL implique une sous-requête corrélée pour récupérer les utilisateurs qui suivent un autre utilisateur. Elle sélectionne le nom d'utilisateur des utilisateurs qui suivent un nombre minimum d'autres utilisateurs. La requête reçoit un paramètre : le nombre minimum d'utilisateurs suivis.

```
SELECT
   username,
(
       SELECT
           COUNT(*)
       FROM
           FOLLOWING F
           F.follower_id = U.id) AS Following_Count
FROM
   Users U
WHERE (
   SELECT
       COUNT(*)
   FROM
       FOLLOWING F
   WHERE
       F.follower_id = U.id) >= :minfollowingcount;
```

### 5.4 Requête SQL pour le Calcul de la Popularité Moyenne des Utilisateurs Suivis par Pays

Cette requête SQL implique une sous-requête dans le FROM. Elle sélectionne le nom du pays et la popularité moyenne des utilisateurs suivis par pays.

```
SELECT

CO.name AS Country_Name,

AVG(PopularityScores.Popularity) AS Average_Popularity
FROM

Countries AS CO

JOIN (
```

```
SELECT
           COUNT(*) AS Popularity,
           UL.city_code
       FROM
           FOLLOWING AS F
           JOIN Users AS U ON F.followed_id = U.id
           JOIN UserLocations AS UL ON U.id = UL.user_id
       GROUP BY
           UL.city_code) AS PopularityScores ON CO.country_code =(
       SELECT
           country_code
       FROM
           Cities
       WHERE
           city_code = PopularityScores.city_code)
GROUP BY
   CO.name;
```

# 5.5 Requête SQL pour la Récupération des Utilisateurs Postant Après une Date Spécifique

Cette requête SQL implique une sous-requête dans le WHERE. Elle sélectionne les nom d'utilisateurs qui ont posté après une date spécifique.

```
| SELECT U.username
| FROM Users U
| WHERE U.id IN (SELECT user_id FROM Posts WHERE date > :date)
```

### 5.6 Requête SQL pour la Récupération du Nombre d'Utilisateurs par Pays

Cette requête SQL implique une fonction d'agrégation avec une clause GROUP BY et une clause HAVING. Elle sélectionne le nom de chaque pays et le nombre d'utilisateurs dans chaque pays. Elle n'inclut que les pays ayant un nombre d'utilisateurs supérieur ou égal au nombre minimum d'utilisateurs spécifié.

```
SELECT
   CO.name,
   COUNT(*) AS User_Count
FROM
   UserLocations UL
   JOIN Cities C ON UL.city_code = C.city_code
   JOIN Countries CO ON C.country_code = CO.country_code
GROUP BY
   CO.name
HAVING
   COUNT(*) >= :minusercount;
```

# 5.7 Requête SQL pour la Récupération du Nombre de Publications par Tag avec Réaction Emoji Spécifique

Cette requête SQL implique une fonction d'agrégation avec une clause GROUP BY et une clause HAVING. Elle sélectionne le nom du tag et le nombre de publications associées à chaque tag. Elle n'inclut que les tags ayant un nombre de publications supérieur ou égal au nombre minimum de publications spécifié et ayant la réaction emoji spécifiée.

```
SELECT
T.name,
COUNT(DISTINCT P.id) AS Post_Count
FROM
Tags T
JOIN PostTags PT ON T.id = PT.tag_id
```

```
JOIN Posts P ON P.id = PT.post_id

JOIN Reactions R ON R.post_id = P.id

WHERE

R.emoji = :emoji

GROUP BY

T.name

HAVING

COUNT(DISTINCT P.id) >= :minpostcount;
```

### 5.8 Requête SQL pour le Calcul de la Moyenne du Nombre Maximum de Réactions par Publication

Cette requête SQL calcule la moyenne du nombre maximum de réactions par publication. La moyenne est calculée en groupant d'abord les réactions par post\_id et en comptant le nombre de réactions par publication. Le nombre maximum de réactions par publication est ensuite calculé en groupant les comptes par post\_id et en prenant le compte maximum. Enfin, la moyenne des réactions maximum par publication est calculée en prenant la moyenne des comptes maximums.

```
SELECT

AVG(Max_Reactions) AS Average_of_Max_Reactions

FROM (
SELECT

post_id,
MAX(reactions_count) AS Max_Reactions

FROM (
SELECT

post_id,
COUNT(*) AS reactions_count

FROM
Reactions
GROUP BY
post_id) AS ReactionCounts

GROUP BY
post_id) AS MaxCounts;
```

# 5.9 Requête SQL pour la Récupération des Utilisateurs avec un Type de Participation Spécifique dans des Événements avec un Statut Spécifique

Cette requête SQL implique au moins une jointure externe. Elle récupère les utilisateurs ayant un type de participation spécifié dans des événements avec un statut spécifique. Elle utilise une jointure LEFT JOIN pour inclure les utilisateurs qui peuvent ne pas avoir de dossiers de participation. La requête joint les tables Users, Participation et Events pour récupérer les informations requises.

```
SELECT
U.username,
P.type_participation,
E.name
FROM
Users U
LEFT JOIN Participation P ON U.id = P.user_id
AND P.type_participation = :typeparticipation
LEFT JOIN Events E ON P.event_id = E.id
AND E.status = :eventstatus
WHERE
U.username IS NOT NULL
AND P.type_participation IS NOT NULL
AND E.name IS NOT NULL;
```

### 5.10 Requête SQL pour la Récupération des Utilisateurs Ayant Réagi à Toutes les Publications d'un Utilisateur Spécifié

Cette requête SQL exprime une condition de totalité avec des sous-requêtes corrélées. Elle récupère les utilisateurs qui ont réagi à toutes les publications d'un utilisateur spécifié. Elle utilise une sous-requête corrélée pour vérifier s'il n'y a aucune publication à laquelle l'utilisateur n'a pas réagi.

```
SELECT DISTINCT
   R.user_id
FROM
   Reactions R
WHERE
   NOT EXISTS (
       SELECT
           P.id
       FROM
           Posts P
       WHERE
           P.user_id = :userid
           AND NOT EXISTS (
               SELECT
                  1
               FROM
                  Reactions R2
                  R2.user_id = R.user_id
                  AND R2.post_id = P.id));
```

# 5.11 Requête SQL pour la Récupération des Utilisateurs Ayant Réagi à Toutes les Publications d'un Utilisateur Spécifié avec une Fonction d'Agrégation

Cette requête SQL exprime une condition de totalité avec une fonction d'agrégation. Elle récupère les utilisateurs qui ont réagi à toutes les publications d'un utilisateur spécifié.

```
SELECT
   R.user_id
FROM
   Reactions R
   JOIN Posts P ON R.post_id = P.id
   P.user_id = :userid
GROUP BY
   R.user_id
HAVING
   COUNT(DISTINCT P.id) =(
       SELECT
           COUNT(*)
       FROM
           Posts
       WHERE
           user_id = :userid);
```

# 5.12 Requête SQL pour Récupérer les Identifiants des Publications qui Ne Sont Pas des Réponses à d'Autres Publications

Cette requête retourne les identifiants des publications qui ne sont pas des réponses à d'autres publications. En raison des valeurs NULL dans la colonne parent\_post\_id, une approche différente est nécessaire.

```
SELECT
P1.id
```

```
FROM
Posts P1
EXCEPT
SELECT
P2.parent_post_id
FROM
Posts P2;
```

### 5.13 Requête SQL pour Récupérer les Identifiants des Publications qui Ne Sont Pas des Réponses à d'Autres Publications

Cette requête retourne les identifiants des publications qui ne sont pas des réponses à d'autres publications. En raison des valeurs NULL dans la colonne parent\_post\_id, une approche différente est nécessaire.

```
SELECT DISTINCT
P1.id
FROM
Posts P1
WHERE
NOT EXISTS (
SELECT
*
FROM
Posts P2
WHERE
P1.id = P2.parent_post_id);
```

### 5.14 Requête SQL pour Récupérer les Identifiants des Publications qui Ne Sont Pas des Réponses à d'Autres Publications

#### 5.14.1 Approche Incorrecte

Cette requête retourne les identifiants des publications qui ne sont pas des réponses à d'autres publications. En raison des valeurs NULL dans la colonne parent\_post\_id, une approche différente est nécessaire.

```
SELECT DISTINCT
P1.id
FROM
Posts P1
WHERE
P1.id NOT IN (
SELECT
P2. parent_post_id
FROM
Posts P2);
```

#### 5.14.2 Approche Correcte

La solution consiste à utiliser une sous-requête pour filtrer les valeurs parent\_post\_id qui ne sont pas NULL.

```
SELECT DISTINCT
P1.id
FROM
Posts P1
WHERE
P1.id NOT IN (
SELECT
P2. parent_post_id
```

```
FROM
Posts P2
WHERE
P2. parent_post_id IS NOT NULL);
```

### 5.15 Requête SQL pour Récupérer le Prochain Événement Planifié

Cette requête retourne le prochain événement planifié à partir de la table 'Events'. Elle utilise une CTE récursive pour générer une séquence de dates à partir d'aujourd'hui. La requête joint ensuite cette séquence avec la table 'Events' pour trouver le prochain événement planifié. Le résultat inclut le nom de l'événement, la date et l'heure complètes, ainsi que le statut.

```
WITH RECURSIVE DateSeq AS (
       SELECT
           NOW()::date AS event_date -- Start from today, only the date part
       UNION ALL
       SELECT
           (event_date + INTERVAL '1 day')::date
       FROM
           DateSeq
       WHERE
           event_date <(
              SELECT
                  MAX(date)::date
              FR.OM
                  Events)
              -- Up to the max date only, ignoring time
   )
   SELECT
       COALESCE(E.name, 'No event scheduled') AS event_name,
       E.date AS event_full_datetime,
       E.status
   FROM
       DateSeq
       LEFT JOIN Events E ON DateSeq.event_date = E.date::date -- Compare only the date parts
       DateSeq.event_date >= NOW()::date
       AND E.status = 'Scheduled'
       AND E.id IS NOT NULL
   ORDER BY
       DateSeq.event_date ASC
   LIMIT 1;
```

# 5.16 Requête SQL pour Récupérer les 10 Meilleurs Événements avec le Plus de Participants en une Année Donnée

Cette requête retourne les 10 événements avec le plus de participants pour une année donnée. Elle utilise une fonction de fenêtre pour classer les événements par le nombre de participants en ordre décroissant. Le résultat inclut le nom de l'événement, la date et le rang. La requête filtre les événements par l'année spécifiée et ordonne les résultats par rang et date.

```
SELECT DISTINCT
    E.name,
    E.date,
    RANK() OVER (PARTITION BY EXTRACT(MONTH FROM E.date) ORDER BY COUNT(P.user_id) DESC) AS
    Rank
FROM
    Events E
    JOIN Participation P ON E.id = P.event_id
GROUP BY
    E.name,
    E.date
```

```
HAVING
EXTRACT(YEAR FROM E.date) = :year
ORDER BY
Rank ASC,
E.date ASC
LIMIT 10;
```

### 5.17 Requête SQL pour Récupérer le Nombre de Publications par Utilisateur

Cette requête récupère le nombre de publications faites par chaque utilisateur. Le résultat inclut le nom d'utilisateur et le nombre total de publications.

```
SELECT
U.username,
PostCount.PostsCount

FROM
Users U
JOIN (
SELECT
user_id,
COUNT(*) AS PostsCount

FROM
Posts
GROUP BY
user_id) PostCount ON U.id = PostCount.user_id;
```

### 5.18 Requête SQL pour Trouver Tous les Sous-genres d'un Genre Parent Spécifié

Cette requête utilise une CTE récursive pour trouver tous les sous-genres d'un genre parent spécifié. Le résultat inclut l'identifiant du genre, le nom et l'identifiant du genre parent.

```
WITH RECURSIVE GenresCurrent AS (
       SELECT
           id,
           name,
           parent_genre_id
       FROM
           Genres
       WHERE
           id = :pgid
       UNION ALL
       SELECT
           G.id,
           G.name,
           G.parent_genre_id
       FROM
           Genres G,
           GenresCurrent GC
           GC.id = G.parent_genre_id
   )
   SELECT
   FROM
       GenresCurrent;
```

### 5.19 Requête SQL pour Récupérer les Villes Hébergeant au Moins un Événement avec des Films de Plus de 1h30

Cette requête retourne les villes qui hébergent au moins un événement avec des films de plus de 1h30. Elle calcule la durée moyenne des films projetés dans ces villes. Le résultat inclut le nom de la ville et la durée moyenne des films.

```
SELECT

CI.name AS City_Name,
 AVG(CAST(M.duration AS real)) AS Average_Duration

FROM

Screenings S
 JOIN Movies M ON S.movie_id = M.id
 JOIN Events E ON S.event_id = E.id
 JOIN Cities CI ON E.city_code = CI.city_code

WHERE
 M.duration > 90

GROUP BY
 CI.name;
```

### 5.20 Requête SQL pour Récupérer les Événements Futurs avec Plus de 10 Participants par Mois

Cette requête récupère les événements futurs ayant plus de 10 participants par mois. Le résultat inclut le nom de l'événement, la date et le nombre de participants.

```
E.name AS Event_Name,
E.date AS Event_Date,
COUNT(*) AS Participants_Count
FROM
Events E
JOIN Participation P ON E.id = P.event_id
WHERE
E.date > CURRENT_DATE
GROUP BY
E.name,
E.date
HAVING
COUNT(*) > 10;
```

### 6 Recommandations

Les méthodes utilisées pour la recommandation de films, de posts et d'évènements sont identiques sur le plan technique. En effet, les recommandations sont basées sur les goûts des utilisateurs, déterminés par les films qu'ils ont notés, les posts qu'ils ont aimés et les évènements auxquels ils ont participé.

#### Exemple: Recommandation de films

Tout d'abord, nous calculons la similarité entre les utilisateurs. Par exemple, les similarités entre les films sont calculées en utilisant une formule basée sur le produit scalaire des notes des utilisateurs. Cela implique de comparer les notes données par les mêmes utilisateurs pour différents films.

Dans le cas de la recommandation de films, pour assurer que les similarités calculées sont significatives, seules les paires de films notées par plus d'un utilisateur sont retenues. Cela élimine les cas où la similarité serait basée sur des données insuffisantes.

Les scores de recommandation pour chaque utilisateur et chaque film non encore noté sont ensuite calculés en combinant les similarités des films notés avec les notes données par l'utilisateur. Cela se fait via une somme pondérée des similarités et des notes. Les films déjà notés par l'utilisateur sont exclus de ce calcul pour ne recommander que des films nouveaux.

Les recommandations calculées sont ensuite insérées dans une table permanente *MovieRecommendation*. En cas de conflit (si une recommandation existe déjà pour un utilisateur et un film), la recommandation est mise à jour avec le nouveau score calculé.

### 7 Conclusion

Pour conclure, nous avons pu démontrer de la robutesse de notre base de données avec les 20 requêtes SQL que nous avons présentées. Ces requêtes couvrent un large éventail de cas d'utilisation, allant de la récupération de données simples à des requêtes plus complexes impliquant des jointures, des sous-requêtes, des CTE récursives et des fonctions de fenêtrage. Nous avons également fourni des solutions alternatives pour certaines requêtes, en mettant en évidence les erreurs courantes et en proposant des approches correctes. Enfin, nous avons fourni des explications détaillées pour chaque requête, en mettant en évidence les concepts SQL sous-jacents et en expliquant les raisons de chaque étape.